

UNIVERSIDAD DE MURCIA Grado en Ingeniería Informática

Traducción de miniC a código ensamblador de MIPS

Compiladores 2024/2025 2^{0} Grado en Ingeniería Informática

Índice general

1.	Definición del problema	2			
2.	Definición de los lenguajes fuente y destino	3			
	2.1. Definición de $miniC$	3			
	2.1.1. Símbolos terminales	3			
	2.1.2. Una sintaxis para $miniC$	4			
	2.2. Descripción del código ensamblador de MIPS	5			
	2.3. Ejemplo de entrada/salida	8			
3.	. Práctica 1: Análisis de léxico con Flex				
4.	4. Práctica 2: Análisis sintáctico con Bison				
5.	. Práctica 3: Análisis semántico y generación de código MIPS				
6.	Tarea final: Ejecución y evaluación del código generado				
7.	. Evaluación y normas de presentación				

Definición del problema

Esta práctica va a consistir en la implementación de un compilador que traduce desde el lenguaje fuente denominado miniC al lenguaje ensamblador de MIPS. Este proceso de traducción requiere desarrollar e integrar las siguientes fases:

- Análisis de léxico.
- Análisis sintáctico.
- Análisis semántico.
- Generación de código ensamblador.

A medida que se vayan elaborando estas fases del compilador, será necesario verificar su correcta implementación, tanto con programas de entrada válidos como con programas que contengan errores en los distintos niveles de análisis. Igualmente, se deberá verificar que el código MIPS generado es equivalente semánticamente al programa miniC de entrada.

El lenguaje usado para la implementación del compilador será C en un entorno tipo Linux. Por tanto, se emplearán las herramientas gcc y make. Además, la implementación de las fases de análisis se apoyará en herramientas que permiten generar código C a partir de expresiones regulares o gramáticas libres de contexto:

- → flex para generar automáticamente el analizador léxico.
- \rightarrow bison para generar automáticamente el analizador sintáctico.

Para verificar el programa ensamblador resultante de la traducción, se podrá usar spim o Mars, a modo de intérprete de MIPS (máquina virtual).

Definición de los lenguajes fuente y destino

2.1. Definición de miniC

Partiremos de un lenguaje al que hemos llamado *miniC*, una versión de C muy simplificada con las siguientes restricciones:

- Sólo manejaremos constantes y variables enteras.
- El lenguaje permite operadores aritméticos de valores enteros.
- No hay operadores relacionales ni lógicos en la versión básica del lenguaje.
- En consecuencia, las expresiones aritméticas de enteros se podrán utilizar como condiciones lógicas de forma similar a C (0 es falso y todos los demás enteros son verdadero).
- No hay definición de funciones salvo la del programa principal.

2.1.1. Símbolos terminales

- Valores literales
 - Enteros: sólo serán válidos los enteros con signo con valores entre -2^{31} y 2^{31} , para poder representarlos con el tipo word (4 bytes) en el ensamblador de MIPS.
 - <u>Cadenas de caracteres</u>: Secuencias de caracteres delimitadas por comillas dobles. Pueden contener dobles comillas siempre que estén precedidas de contrabarra \". También pueden contener caracteres de escape (tabulador \t, salto de línea \n y retorno de carro \r).
- Identificadores: Secuencia de letras, dígitos, y símbolos de subrayado, que no comienza por dígito y no excede los 32 caracteres.
- Palabras reservadas: var, const, int, if, else, while, print y read.
- Caracteres especiales: ;, ,, +, -, *, /, =, (,),{,}, ?, :.

2.1.2. Una sintaxis para miniC

```
id ( ) { declarations statement list }
program
                      declarations var tipo var list;
declarations
                      declarations const tipo const list;
                      \lambda
tipo
                      int
var_list
                      id
                      var_list , id
                     id = expression
const list
                      const list, id = expression
                      statement list statement
statement list
statement
                     id = expression;
                      { statement list }
                      {\tt if} ( {\tt expression} ) statement {\tt else} statement
                      if (expression) statement
                      while (expression) statement
                      print ( print list );
                      read ( read_list ) ;
                      print_item
print_list
                      print list, print item
                      expression
print item
                      string
read list
                      id
                      \operatorname{read}_list , id
expression
                      expression + expression
                      expression - expression
                      expression * expression
                      expression / expression
                      (expression ? expression : expression)
                      - expression
                      (expression)
                      id
                      num
```

Esta gramática está en notación BNF, y por tanto puede ser usada directamente para construir la especificación del analizador sintáctico con Bison.

2.2. Descripción del código ensamblador de MIPS

En el desarrollo de esta práctica emplearemos un subconjunto del ensamblador de MIPS. Este conjunto es suficiente para la implementación de la práctica aquí descrita, pero puede ser necesario ampliarlo si, opcionalmente, se desea aumentar el lenguaje de entrada con nuevas características.

El fichero ensamblador de salida generado al compilar un fichero de miniC debe comenzar con una representación de la tabla de símbolos construida durante el proceso de análisis. Esta tabla debe tener el siguiente formato:

```
.data
    # Cadenas del programa
    $str1:
             .asciiz "Cadena1"
5
    $str2:
6
             .asciiz "Cadena2"
    $str3:
             .asciiz "Cadena3"
9
10
    # Variables y constantes
11
    _{\mathrm{x}}:
12
             .word 0
13
14
    _y:
15
             .word 0
    _z:
16
             .word 0
17
```

La tabla de símbolos se encuentra en el segmento de datos del programa, conforme establece la primera línea con .data. Los comentarios en ensamblador MIPS quedan indicados con #, y son opcionales. Cada cadena de caracteres encontrada en el programa fuente quedará reflejada en la sección de datos con una posición de memoria indicada usando un identificador con el formato \$strX, donde X es un contador que comenzará en 1 y se incrementará en una unidad por cada cadena encontrada. Las cadenas se deben almacenar como texto ascii terminado en un carácter nulo, mediante la directiva .asciiz.

Las variables o constantes enteras pueden situarse en la sección de datos como memoria de tipo .word, es decir, como datos de 32 bits. La inicialización de su valor será siempre a 0. El nombre de la variable se empleará como identificador de la posición de memoria de la variable, pero deberá ir precedido del carácter _ con el fin de evitar que los nombres de variables usados por el usuario en el fichero de entrada puedan colisionar con nombres de operaciones del ensamblador de MIPS.

A continuación de la sección de datos, comenzará la sección de texto que contiene las instrucciones del código ensamblador. En esta sección se debe definir forzosamente el punto de entrada al programa, que será una posición etiquetada con main y declarada con .globl:

```
1    .text
2
3    .globl main
4  main:
5     # Aquí comienzan las instrucciones del programa
```

Para la implementación de la práctica serán suficientes algunas instrucciones del ensamblador MIPS:

Instrucción	Descripción	Ejemplo	
li reg, val	Carga en el registro reg el valor inmediato val .	li \$t1, 50	
lw reg, mem	Carga en el registro reg el valor word almacenado en la posición de memoria	lw \$t1, _x	
	indicada por mem.		
la reg, mem	Carga en el registro reg la posición de	la \$a0, \$str1	
	memoria indicada por mem.		
sw reg, mem	Almacena en la memoria indicada por	sw \$t1, _x	
	mem el valor word del registro reg.		
move reg1, reg2	Copia al registro reg1 el valor del registro reg2.	move \$a0, \$t1	
add regs, reg1, reg2	Suma el valor del registro reg1 con el	add \$t3, \$t1, \$t2	
	del registro reg2 y almacena el resulta-		
	do en el registro regs.		
addi regs, reg1, val	Suma el valor del registro reg1 con el	addi \$t3, \$t1, 1	
	valor entero val y almacena el resulta-		
	do en el registro regs.		
sub regs, reg1, reg2	Resta al valor del registro reg1 el del	sub \$t3, \$t1, \$t2	
	registro reg2 y almacena el resultado en el registro regs.		
mul regs, reg1, reg2	Multiplica el valor del registro reg1 por	mul \$t3, \$t1, \$t2	
mai 10gb, 10g1, 10g2	el del registro reg2 y almacena el resul-	mui 400, 401, 402	
	tado en el registro regs.		
div regs, reg1, reg2	Divide el valor del registro reg1 por el	div \$t3, \$t1, \$t2	
	del registro reg2 y almacena el resul-		
	tado en el registro regs. La división es		
	entera.		
neg regs, reg	Invierte el signo del valor del registro	neg \$t2, \$t1	
	reg y almacena el resultado en el regis-		
	tro regs.		
b etiq	Salto incondicional a la posición de có-	b \$11	
	digo indicada por etiq	3 4 4 4 7 4	
beqz reg, etiq	Salto a la posición de código indicada	beqz \$t1, \$11	
	por etiq en el caso de que el valor del		
hnez reg etig	registro reg sea igual a cero. Salto a la posición de código indicada	bnez \$t1, \$11	
bnez reg, etiq	por etiq en el caso de que el valor del	DHez wil, wil	
	registro reg no sea igual a cero.		
syscall	Llamada a un servicio del sistema (ver	syscall	
,	más adelante)	J	
jal etiq	Salta a la posición de código indicada		
-	por etiq y guarda en \$ra la dirección		
	de retorno		
jr \$ra	Salta a la posición de código indicada		
	por el registro \$ra		

Los saltos a posiciones de código tienen siempre un argumento que es una etiqueta de salto. Las etiquetas de salto se establecen en el código ensamblador mediante una cadena terminada con dos puntos:

\$11:

Aquí comienzan las instrucciones apuntadas por \$11

En la arquitectura MIPS, existen 32 registros cuyo uso sigue una convención, tal y como se lista a continuación:

Nombre del registro	Número	Uso
\$zero	0	Constante 0.
\$at	1	Reservada.
v0	2	Evaluación de expresiones y resultados de una función.
\$v1	3	Evaluación de expresiones y resultados de una función.
\$a0	4	Argumento 1 de una función.
\$a1	5	Argumento 2 de una función.
a2	6	Argumento 3 de una función.
\$a3	7	Argumento 4 de una función.
\$t0	8	Variable temporal volátil (no preservada en llamadas).
\$t1	9	Variable temporal volátil (no preservada en llamadas).
\$t2	10	Variable temporal volátil (no preservada en llamadas).
\$t3	11	Variable temporal volátil (no preservada en llamadas).
\$t4	12	Variable temporal volátil (no preservada en llamadas).
\$t5	13	Variable temporal volátil (no preservada en llamadas).
\$t6	14	Variable temporal volátil (no preservada en llamadas).
\$t7	15	Variable temporal volátil (no preservada en llamadas).
s0	16	Variable temporal no volátil (preservada en llamadas).
\$s1	17	Variable temporal no volátil (preservada en llamadas).
s2	18	Variable temporal no volátil (preservada en llamadas).
s3	19	Variable temporal no volátil (preservada en llamadas).
\$s4	20	Variable temporal no volátil (preservada en llamadas).
\$s5	21	Variable temporal no volátil (preservada en llamadas).
\$s6	22	Variable temporal no volátil (preservada en llamadas).
\$s7	23	Variable temporal no volátil (preservada en llamadas).
\$t8	24	Variable temporal volátil (no preservada en llamadas).
\$t9	25	Variable temporal volátil (no preservada en llamadas).
\$k0	26	Reservada para el kernel del SO.
\$k1	27	Reservada para el kernel del SO.
\$gp	28	Puntero a área global.
p	29	Puntero a la pila.
\$fp	30	Puntero al frame de llamada.
\$ra	31	Dirección de retorno (usada en llamadas a funciones).

De estos registros, los más prácticos para la implementación del compilador son los registros temporales \$t0-\$t9 o \$s0-\$s7.

El lenguaje miniC permite la utilización de la instrucción print para la generación de información por la salida estándar. La información que se puede enviar a salida estándar es, o bien una cadena de caracteres, o bien un valor entero. Para generar esta salida es necesario traducir estas operaciones de impresión mediante llamadas a servicios del sistema, usando syscall. Dichas llamadas funcionan cargando, en primer lugar, el identificador del servicio que se desea invocar en el registro \$v0, y el dato que se desea imprimir en el registro \$a0.

Por ejemplo, el servicio de impresión de una cadena de caracteres tiene el código de llamada 4, y el registro \$a0 debe contener la dirección de comienzo de la cadena:

```
li $v0, 4
2 la $a0, $str
3 syscall
```

Para imprimir un entero se debe usar la llamada con código 1, almacenando previamente en \$a0 el valor a imprimir. Si ese valor se encuentra en el registro \$ti, siendo \$ti uno de los registros temporales \$t0-\$t9:

El lenguaje miniC también permite la utilización de la instrucción read para la lectura de valores enteros. Para leer un entero con el ensamblador de MIPS, se debe usar la llamada al sistema con código 5. El valor leído se almacena en el registro \$v0, de modo que una instrucción miniC como read x producirá el código ensamblador siguiente:

```
li $v0, 5
2 syscall
3 sw $v0, _x
```

Para finalizar el programa producido por el compilador, se realiza una llamada al sistema de tipo exit:

```
# Final: exit
li $v0, 10
syscall
```

2.3. Ejemplo de entrada/salida

El siguiente fichero de entrada en miniC:

```
prueba() {
     const int a = 0, b = 0;
2
     var int c;
     print ("Inicio del programa\n");
     c = 5+2-2;
     if (a) print ("a","\n");
6
     else if (b) print ("No a y b\n");
           else while (c) {
                  print ("c = ",c,"\n");
9
                  c = c-2+1;
10
11
     print ("Final","\n");
12
   }
13
```

puede traducirse a una salida parecida a la siguiente:

```
9 $str3:
   .asciiz "\n"
  $str4:
   .asciiz "No a y b\n"
12
   $str5:
13
   .asciiz "c = "
14
   $str6:
15
   .asciiz "\n"
16
   $str7:
17
      .asciiz "Final"
   $str8:
   .asciiz "\n"
20
   _a:
21
       .word 0
^{22}
   _b:
23
      .word 0
24
   _c:
25
       .word 0
26
27
   ###################
28
   # Seccion de codigo
29
       .text
30
       .globl main
31
   main:
32
       li $t0, 0
33
       sw $t0, _a
       li $t0, 0
35
       sw $t0, _b
36
       la $a0, $str1
37
       li $v0, 4
38
39
       syscall
       li $t0, 5
40
       li $t1, 2
41
       add $t2, $t0, $t1
42
       li $t0, 2
43
       sub $t1, $t2, $t0
44
       sw $t1, _c
45
       lw $t0, _a
46
       begz $t0, $15
47
       la $a0, $str2
48
       li $v0, 4
       syscall
50
       la $a0, $str3
51
       li $v0, 4
52
       syscall
53
       b $16
54
55 $15:
       lw $t1, _b
56
       beqz $t1, $13
       la $a0, $str4
58
       li $v0, 4
59
       syscall
60
       b $14
61
   $13:
62
   $11:
63
       lw $t2, _c
64
       beqz $t2, $12
       la $a0, $str5
66
```

```
li $v0, 4
67
       syscall
68
       lw $t3, _c
       move $a0, $t3
70
       li $v0, 1
71
       syscall
72
       la $a0, $str6
73
       li $v0, 4
74
       syscall
75
       lw $t3, _c
       li $t4, 2
77
       sub $t5, $t3, $t4
78
       li $t3, 1
79
       add $t4, $t5, $t3
       sw $t4, _c
81
       b $11
82
   $12:
83
   $14:
   $16:
85
       la $a0, $str7
86
       li $v0, 4
87
       syscall
       la $a0, $str8
89
       li $v0, 4
90
       syscall
91
   ##############
93
   # Fin
94
       li $v0, 10
95
       syscall
```

Práctica 1: Análisis de léxico con Flex

Tareas

- Identificación de los tokens que aparecen en la definición de la gramática de 2.1. En particular, el analizador léxico deberá reconocer:
 - Las palabras reservadas y los caracteres especiales.
 - Identificadores, números y cadenas.
- **Definición de expresiones regulares** (tipo *Flex*) correspondientes a cada uno de esos tokens y de aquellas que sirvan para reconocer comentarios tipo C.
 - Los comentarios multilínea comienzan por /* y terminan con */.
 - Los comentarios de línea comienzan con //.
- Creación del fichero *Flex* que genere el fichero C para reconocer la secuencia de tokens correspondiente a un programa de entrada dado, ignorando los comentarios y espacios en blanco que puedan aparecer.
- Implementación de la recuperación de errores en modo pánico.
- Verificar la corrección del analizador léxico usando ficheros de prueba que deberán incluirse en la entrega de la práctica y comentarse en la memoria.

Práctica 2: Análisis sintáctico con Bison

Tareas

- Inclusión en el fichero Flex anterior de acciones para devolver atributos al analizador sintáctico.
- Crear el fichero *Bison*, que funcione conjuntamente con el analizador léxico, para reconocer sintácticamente ficheros descritos por la gramática de miniC. Para ello, será necesario:
 - Estudiar la necesidad de definir precedencias y asociatividades para los operadores aritméticos, con el fin de que las expresiones no sean ambiguas.
 - Añadir las acciones semánticas necesarias para generar la secuencia de reglas aplicadas para reconocer un programa de entrada.
- Estudiar los posibles conflictos desplazamiento/reducción y reducción/reducción.
- Realizar, opcionalmente, una recuperación de errores.
- Verificar la corrección del analizador sintáctico usando ficheros de prueba que deberán incluirse en la entrega de la práctica y comentarse en la memoria.

Práctica 3: Análisis semántico y generación de código MIPS

Análisis semántico

Consistirá básicamente en la gestión de declaración y uso de variables y constantes. Para hacerlo:

- Hay que definir la tabla de símbolos como una estructura de datos que permita almacenar las variables, constantes y cadenas declaradas en el programa. Se proporcionará una implementación de la tabla¹ para facilitar la tarea, aunque su uso no es obligatorio.
- Será necesario dar de alta a las variables y constantes en la tabla de símbolos cuando aparezcan en una declaración. Esto podrá llevarse a cabo con acciones en las reglas de producción que van generando las declaraciones de variables. Inicialmente sólo se permiten enteros de tipo word.
- Será necesario **controlar** que una variable o constante no se declare más de una vez, y que no se use sin haber sido declarada. También será necesario controlar que no se reasignen valores a las constantes. En otro caso, se emitirá un mensaje de error.
- Verificar la corrección del analizador semántico usando ficheros de prueba que deberán incluirse en la entrega de la práctica y comentarse en la memoria.

Generación de código

Para realizar esta tarea se proporcionará una implementación de un tipo lista en C, con la estructura de datos en la que iremos almacenando el código generado². Cada sentencia de *miniC* corresponderá a un conjunto de operaciones, implementadas cada una de ellas como una estructura con cuatro campos, es decir, en forma de cuádruplas. El código de salida será, por tanto, una lista enlazada (dinámica) de cuádruplas. Tenemos fundamentalmente dos opciones para conseguirlo:

■ La primera consiste en asociar a cada no terminal principal de la gramática, un atributo del tipo lista (de código). Habría que ir uniendo listas enlazadas en una única lista cada vez que necesitemos concatenar código según la construcción ascendente del árbol sintáctico para, finalmente, terminar con la lista enlazada correspondiente al código completo, como contenido de un atributo asociado a los símbolos declarations y statement_list de la regla

¹En la carpeta "Lista de símbolos" que encontraréis dentro de "Prácticas" en los Recursos del Aula Virtual.

²En la carpeta "Lista para código" que encontraréis dentro de "Prácticas" en los Recursos del Aula Virtual.

- de **program**. Debemos construir una función para imprimir las listas de código en el fichero de salida a continuación de la tabla de símbolos.
- También sería posible trabajar con una estructura global que se iría actualizando conforme se va reconociendo el programa fuente. En este caso habría que usar acciones en mitad de las reglas de producción de Bison y el acceso directo a valores de la pila de dicha herramienta. También se necesita una función para imprimir el código completo en el fichero de salida, a continuación de la tabla de símbolos.

En cualquier caso debemos añadir al fichero bison los **atributos** y las **acciones semánticas** necesarias para generar código con el formato de la sección 2.2. Para esto:

- Usaremos la *tabla de símbolos* para **generar** la primera parte del programa en ensamblador, es decir, **la sección de datos**. Es importante observar que los registros \$t0-\$t9 o \$s0-\$s7 se pueden usar como variables temporales que no es necesario declarar en la tabla de símbolos.
- Añadiremos además, a cada regla de producción, las acciones en C necesarias para traducir, por un lado las expresiones aritméticas y, por otro, las sentencias de control del lenguaje fuente a código MIPS. De esta forma, completaremos el programa objeto con la sección de código.
- Finalmente, debemos **verificar la corrección** del código generado usando ficheros de prueba que deberán incluirse en la entrega de la práctica y comentarse en la memoria, mostrando la salida de su ejecución con **spim** o Mars.

Tarea final: Ejecución y evaluación del código generado

- Ejecutar las prácticas realizadas a lo largo del curso con diferentes programas de entrada:
 ./minic programa.mc > programa.s
 donde la extensión .mc se puede utilizar para representar a ficheros fuente escritos en miniC.
- Usar la salida generada en código ensamblador como entrada del intérprete spim o Mars:
 ./spim -file programa.s
- Comprobar que el código funciona tal y como esperábamos cuando escribimos el programa fuente.

Evaluación y normas de presentación

Para la **evaluación** de la parte práctica de la asignatura (ver guía docente) se tendrán en cuenta las siguientes consideraciones:

- Debe realizarse, en la medida de lo posible, por parejas.
- Para aprobar la parte de prácticas de la asignatura es necesaria la correcta implementación de la parte obligatoria de las prácticas, que consiste en la validación y la generación de código de todas las sentencias del lenguaje miniC indicadas en la gramática del enunciado.
- La parte obligatoria de las prácticas puntúa hasta 8.
- Se podrán implementar mejoras para obtener hasta un 10, siguiendo este orden:
 - 1. La implementación de una sentencia do-while se valora con 0,5 puntos adicionales.
 - 2. La implementación de los operadores relacionales (<, >, <=, >=, ==, !=) para las condiciones de las sentencias se valora con 0,5 puntos adicionales.
 - 3. La implementación de una sentencia for se valora con 1 punto adicional. La sintaxis de la sentencia es libre, pero deberá ser de tal forma que:
 - El programador tendrá que especificar el valor mínimo y máximo que tomará una variable previamente declarada con la cual se controla el bucle.
 - El programador no tendrá que incluir un código para incrementar el valor de la variable, sino que se actualizará automáticamente con un paso 1 (opcionalmente se puede implementar la sentencia for de forma que el programador pueda indicar un paso de actualización distinto).
 - La condición de finalización se podrá expresar con operadores relacionales.
- La obtención de la puntuación indicada está condicionada al correcto funcionamiento del compilador, siguiendo las especificaciones de este documento. Se considerará suspensa cualquier práctica que, en alguno de sus módulos (léxico, sintáctico, semántico o generación de código) no supere el proceso de verificación o provoque violaciones de segmento.
- En caso de que se le convoque a una entrevista de prácticas, debe contestar de forma satisfactoria a las cuestiones planteadas.
- Será necesario entregar:
 - Los fuentes, que habrá que subir al Aula Virtual (como respuesta a la correspondiente tarea), junto con un makefile. Sólo debe entregarse el código realizado por los alumnos.

- Ficheros de prueba que verifiquen el correcto funcionamiento del compilador, incluyendo todos los operadores y sentencias posibles implementados en el lenguaje.
- Una memoria en la que se indique claramente: Nombre y correo electrónico de los componentes del grupo, convocatoria, explicación completa de la práctica (funciones principales, estructuras de datos, manual de usuario para la ejecución, etc.) y ejemplos de funcionamiento explicados (con la entrada y salida correspondientes). En caso de implementar alguna mejora, será obligatoria la inclusión de una sección en la que se describa de forma completa la solución propuesta, teniendo en cuenta las ampliaciones requeridas en todas las fases del compilador.
- Para superar la parte práctica de la asignatura será necesario obtener la calificación de **apto** en el control de prácticas que será convocado junto con el examen de la parte de teoría.

Bibliografía

[AHO] Alfred V. Aho, Monica Lam, Ravi Sethi, Jeffrey D. Ullman, Compiladores. Principios, Técnicas y Herramientas, Addison-Wesley, 2008.

[DON] C. Donnelly y R. Stallman, Bison. The Yacc-compatible parser generator, v2.4.2 (2010).

[PAX] V. Paxson. Lexical Analysis With Flex (2007).

[SPIM] J. Larus, A MIP32 Simulator. http://spimsimulator.sourceforge.net.